Explorando corpus con R: las palabras en acción

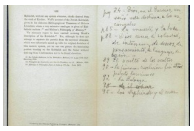
Del archivo histórico al análisis textual estadístico

Romina De León

IIBICRIT CONICET HUMANIDADES DIGITALES LAB

1. El análisis textual estadístico

- **Close Reading** Lectura intensiva / Hermenéutica tradicional
- **Distant Reading** Lectura distante / Estadística textual
- **Del documento al dato estructurado**



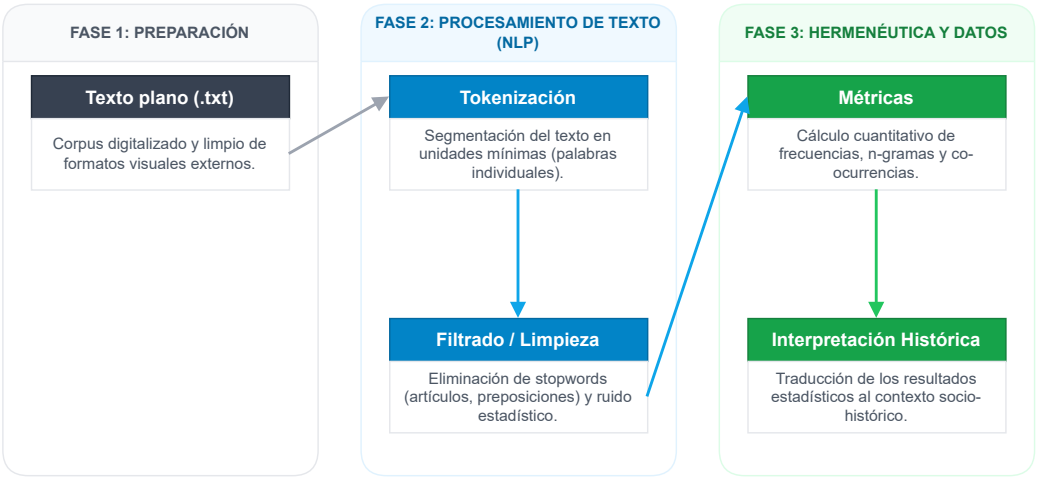
Hoja escrita por Jorge Luis Borges en una edición del libro The Kabbalah de Christian Ginsburg. Biblioteca Nacional Mariano Moreno.



Edición digital de Relación de las cosas sucedidas. Pero Hernández, 1545.

2. Aplicación en la investigación histórica y humanística

- ¿Para qué cuantificar el lenguaje del corpus?
  - Énfasis y fijaciones léxicas: Identificación de conceptos persistentes en el discurso.
  - Categorización y alteridad: Rastreo de fórmulas discursivas particulares
  - Series textuales: Variación del vocabulario a lo largo del tiempo o entre diferentes autores/cronistas
  - Reproducibilidad: Procesos transparentes y auditables mediante código.



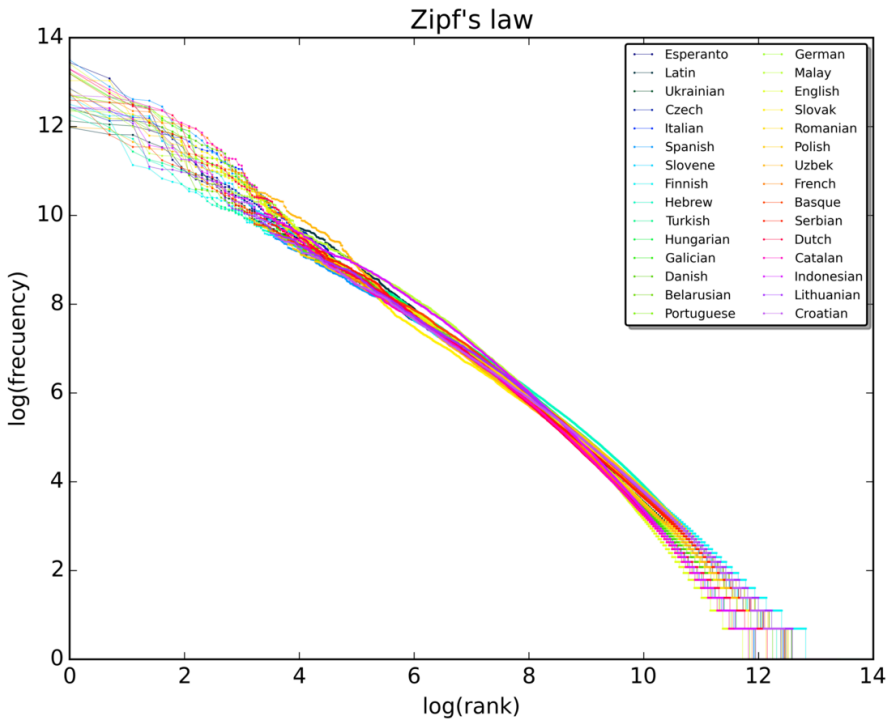
3. Introducción a las regularidades estadísticas

El lenguaje no es aleatorio, sino que se rige por distribuciones de probabilidad y regularidades matemáticas

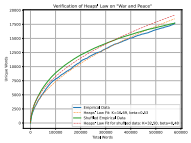
- Frecuencias absolutas vs. relativas
- Ley de Zipf (Rango vs. Frecuencia)
- Ley de Heaps (Crecimiento del vocabulario)



Comparativas de métricas



Verificación de la Ley de Zipf generada por Sergio Jimenez de Wikimedia.



Verificación de la Ley de Heaps en la novela Guerra y paz de León Tolstói

generada por usuario de Wikimedia.

---

4. Ahora a trabajar