Explorando corpus con R: las palabras en acción

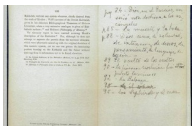
Del documento al análisis textual estadístico

Romina De León

IIBICRIT CONICET HUMANIDADES DIGITALES LAB

1. El análisis textual estadístico

- **Close Reading** Lectura intensiva / Hermenéutica tradicional
- **Distant Reading** Lectura distante / Estadística textual
- **Del documento al dato estructurado**

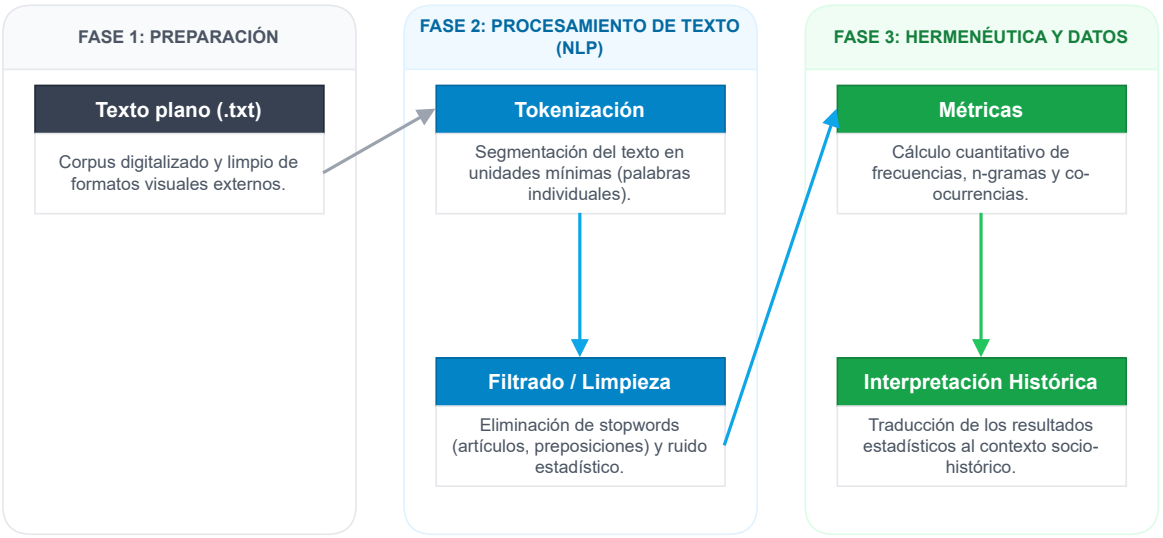


The Kabbalah de Christian Ginsburg. con notas de Jorge Luis Borges.



Edición digital de Relación de las cosas sucedidas. Pero Hernández, 1545.

2. Aplicación en la investigación histórica y humanística



--

¿Para qué cuantificar el lenguaje del corpus?

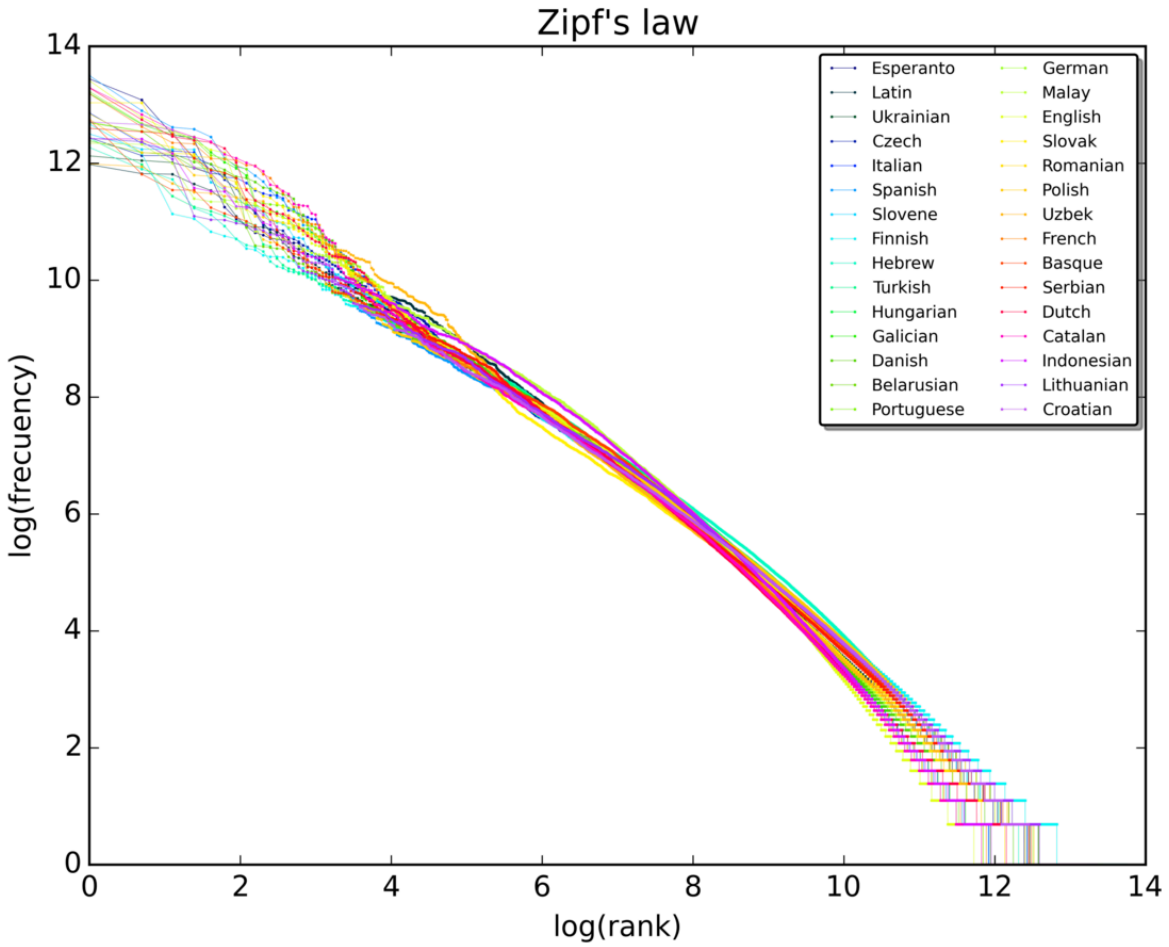
- Fijaciones léxicas y énfasis discursivos
- Detección de alteridades y voces en el archivo
- Evolución y cambios estilísticos
- Estilometría y atribución

3. Introducción a las regularidades estadísticas

El lenguaje no es aleatorio, sino que se rige por distribuciones de probabilidad y regularidades matemáticas

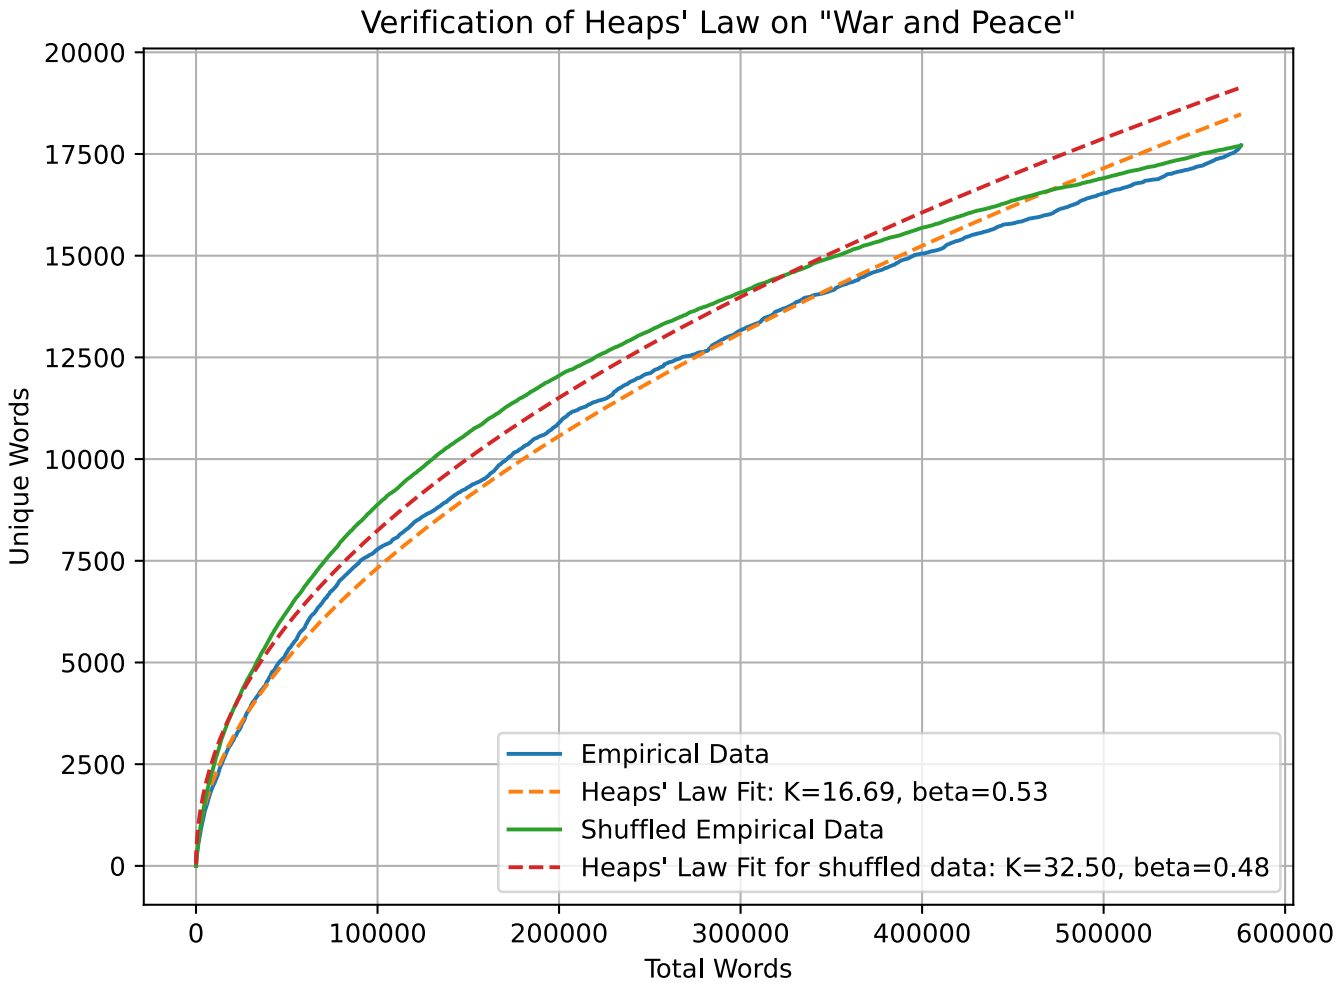
--

Ley de Zipf: Verificación de la relación rango-frecuencia generada por Sergio Jimenez de Wikimedia



--

Ley de Heaps: Verificación del crecimiento del vocabulario en la novela Guerra y paz de León Tolstói generada por usuario de Wikimedia



--

ANÁLISIS TEXTUAL: COMPARATIVA DE MÉTRICAS

Evolución desde la frecuencia simple hasta la ponderación discriminatoria en corpus

1. Frecuencia Absoluta

MEDICIÓN

Conteo bruto directo de apariciones del término en el documento.

LIMITACIÓN

Ignora la longitud del texto y la estructura general del corpus.

APLICACIÓN

Nubes de palabras básicas y exploraciones estilísticas iniciales.

2. Frecuencia Relativa (TF)

MEDICIÓN

Proporción o porcentaje del término frente al total de palabras.

LIMITACIÓN

Ignora la rareza global del término en otros documentos.

APLICACIÓN

Perfilado y comparación entre textos de distinta extensión.

3. TF-IDF

MEDICIÓN

Peso ponderado: frecuencia local escalada por rareza en el corpus.

LIMITACIÓN

Sensible a ruido de stopwords y sesgos si no hay normalización.

APLICACIÓN

Extracción de keywords, motores de búsqueda e indexación.

---

4. Ahora a trabajar